

Compute

Rodzaje klastrów

Typy Compute w Databricks

- [Serverless compute for notebooks](#): Na żądanie, skalowalne użycie SQL lub Python w notatnikach.
- [Serverless compute for jobs](#): Na żądanie, skalowalne użycie do zadań (jobs).
- [All-purpose compute](#): Do notatników, możesz nim zarządzać w Workspace UI, CLI, lub REST API.
- [Jobs compute](#): Do zadań (jobs). Możesz ustawić harmonogram do wykonania zadań. Klaster wyłącza się po skończonym zadaniu.
- [Instance pools](#): Pula instancji, gotowe do użycia nie trzeba czekać aż się uruchomią. Tworzenie przez UI, CLI, lub REST API.
- [Serverless SQL warehouses](#): Na żądanie elastyczny użycie SQL w edytorze SQL lub interaktywnych notatnikach. Tworzenie przez UI, CLI, lub REST API.
- [Classic SQL warehouses](#): Tworzone selektywnie o konkretnej mocy, użycie SQL w edytorze SQL lub interaktywnych notatnikach. Tworzenie przez UI, CLI, lub REST API.
- **Spot Instance**: Tymczasowe VMki pożyczane od Azure, mogą zniknąć (tylko development/testing)

Porównanie klastrów All Purpose i Jobs Compute

All Purpose	Jobs Compute
Tworzone przez użytkownika	Tworzone przez zadania (Jobs)
Działają tak długo jak są używane	Po skończonym zadaniu wyłączane
Do pracy interaktywnej (development)	Dla zadań (workflows)
Drogie	Tańsze

Konfiguracja - Policy

Polityki ograniczają wybór zasobów: koszty i bezpieczeństwo

Są konfigurowane przez administratora

Unrestricted: Wybór klastra bez ograniczeń (możesz wybrać najdroższy 🤖)

Personal Compute: Tylko single node (sam driver)

Power User Compute: Jeśli masz większe potrzeby

Legacy Shared Compute: Stara już nie wspierana

Konfiguracja - Access Mode

Wybierz Access Mode:

Single User

Tylko dla jednego użytkownika

Shared

Dla wielu użytkowników (premium)
Izolacja pomiędzy aplikacjami
Większe bezpieczeństwo

No Isolation Shared

Dla wielu użytkowników
Brak izolacji między aplikacjami
Mniejsze bezpieczeństwo

Konfiguracja - Runtime

Databricks Runtime to najprościej system operacyjny z zainstalowanymi bibliotekami:

Runtime 15.4 LTS:

- Operating System: Ubuntu 22.04.4 LTS
- Java: Zulu 8.78.0.19-CA-linux64
- Scala: 2.12.18
- Python: 3.11.0
- R: 4.3.2
- Delta Lake: 3.2.0

LTS - Long Term Support (3 lata wsparcia)



Photon

- Databricks Photon to wysokowydajny, wektorowy silnik zapytań opracowany w celu przyspieszenia operacji SQL i DataFrame
- Wspiera SQL i operacje na Dataframe z tabelami Delta i Parquet
- Przyspiesza zapytania włączając w to agregacje i łączniki (joins)
- Szybszy dla wielokrotnego odczytu danych z dysku gdyż korzysta z disk cache.
- Szybciej skanuje table z dużą ilością kolumn i małych plików
- Szybszy zapis i operacje na Delta i Parquet `UPDATE`, `DELETE`, `MERGE INTO`, `INSERT`, **and** `CREATE TABLE AS SELECT`
- Zamienia sort-merge joins with hash-joins.
- Możesz go włączyć lub wyłączyć podczas tworzenia klastra

Uwaga klaster z Photonem jest znacznie droższy !!!

Sprawdź na devie zanim zadecydujesz, czy warto go użyć. 

Konfiguracja - Ile potrzebuje maszyn



Pools

Skraca czas oczekiwania na compute

